

13 Kaggle & Dacon 데이터 분석 Case Study





강의 내용

Contents of Lecture

기간	내용	과제
01주차	오리엔테이션 Python 언어의 기본, lpython, 주피터 노트북	-
02주차	내장 자료구조, 함수, 파일	실습 과제
03주차	Numpy 기본 : 배열과 벡터 연산	실습 과제
04주차	Pandas 시작하기	실습 과제
05주차	데이터 로딩과 저장, 파일 형식	실습 과제
06주차	데이터 정제 및 준비(조인, 병합, 변형)	실습 과제
07주차	그래프와 시각화	기말 프로젝트 상세 공지
08주차	중간고사 - 오프라인 오픈북으로 진행	실습 과제

기간	내용	과제
09주차	데이터 집계와 그룹 연산	실습 과제
10주차	시계열	실습 과제
11주차	고급 pandas	실습 과제
12주차	파이썬 모델링 라이브러리	실습 과제
13주차	데이터 분석 예제 / 고급 Numpy	실습 과제
14주차	Kaggle / Dacon 데이터 분석 사례 Case Study	프로젝트 레포트 제출
15주차	[기말고사] Team별 프로젝트 결과 발표	종강~!

1부: Kaggle & Dacon 데이터 분석 Case Study

- 1) Kaggle 사례 4개
- 2) Dacon 사례 3개





Kaggle 데이터 분석 Case Study

≡ kaggle

+ Create

🏠 Home

🏆 Competitions

📊 Datasets

<> Code

💬 Discussions

🎓 Courses

✓ More

🔍 Search

Sign In

Register

Competitions

🔍 Search competitions

⌵ Filters

Analytics X

Results

Reward ▾ 📊



NFL Big Data Bowl 2021

Help evaluate defensive performance on passing plays
Analytics · 0 Teams · a year ago

\$100,000

...



NFL Big Data Bowl 2022

Help evaluate special teams performance
Analytics · 0 Teams · 5 months ago

\$100,000

...



CDP - Unlocking Climate Solutions

City-Business Collaboration for a Sustainable Future
Analytics · 0 Teams · 2 years ago

\$91,000

...



NFL Punt Analytics Competition

Analyze NFL game data and suggest rules to improve player safety during punt plays
Analytics · 0 Teams · 3 years ago

\$80,000

...



NFL 1st and Future - Analytics

Can you investigate the relationship between the playing surface and the injury and performance of NFL athletes?
Analytics · 0 Teams · 2 years ago

\$75,000

...



2019 Kaggle Machine Learning & Data Science Survey

The most comprehensive dataset available on the state of ML and data science
Analytics · 0 Teams · 3 years ago

\$30,000

...

<https://www.kaggle.com/competitions?sortOption=reward&hostSegmentIdFilter=11>



Kaggle 데이터 분석 Case Study > NFL Big Data Bowl 2022

≡ kaggle

+ Create

🏠 Home

🏆 Competitions

📊 Datasets

<> Code

💬 Discussions

🎓 Courses

✓ More

🔍 Search

Sign In

Register

Analytics Competition

NFL Big Data Bowl 2022

Help evaluate special teams performance

The National Football League · 5 months ago

\$100,000

Prize Money

Overview

Data

Code

Discussion

Rules

New Notebook

🔍 Search notebooks

⌵ Filters

All Your Work Shared With You Bookmarks

Most Votes ▾



😊🌟 NFL Big Data Bowl Basic EDA for Beginner !! 🏈

Notebook copied with edits from radmirkaz · Updated 8mo ago
33 comments · NFL Big Data Bowl 2022

▲ 177

🥇 Gold ...



🌟🏈 NFL Big Data Bowl - Beginner's Complete EDA 🏈🌟

Updated 6mo ago
20 comments · NFL Big Data Bowl 2022

▲ 82

🥈 Silver ...



🏈 Tracking data visualization 🏈

Updated 9mo ago
15 comments · NFL Big Data Bowl 2022

▲ 70

🥈 Silver ...



NFL Big Data Bowl 2022 - Starters EDA 🏈🏈

Notebook copied with edits from a private notebook · Updated 9mo ago
0 comments · NFL Big Data Bowl 2022

▲ 56

🥈 Silver ...

<https://www.kaggle.com/competitions/nfl-big-data-bowl-2022>



BAEK KYUN SHIN · COPIED FROM RADMIKAZ +473, -515 · 8MO AGO · 6,609 VIEWS

▲ 177

Copy & Edit

119



😊✨NFL Big Data Bowl Basic EDA for Beginner !! 🏈

Python · [NFL Big Data Bowl 2022](#)

Notebook

Data

Logs

Comments (33)



Competition Notebook
[NFL Big Data Bowl 2022](#)

Run

89.3s



Version 12 of 12

Beginner

Data Visualization

Exploratory Data Analysis

Data Analytics

Tabular Data

NFL Big Data Bowl Basic EDA for beginner



<https://www.kaggle.com/code/werooring/nfl-big-data-bowl-basic-eda-for-beginner>



Kaggle 데이터 분석 Case Study > CDP - Unlocking Climate Solutions

≡ kaggle

+ Create

🏠 Home

🏆 Competitions

📁 Datasets

<> Code

💬 Discussions

🎓 Courses

✓ More

📅 View Active Events

🔍 Search

Sign In

Register

Analytics Competition

CDP - Unlocking Climate Solutions

City-Business Collaboration for a Sustainable Future

2 years ago

CDPTM

\$91,000
Prize Money

[Overview](#) [Data](#) [Code](#) [Discussion](#) [Rules](#)

[New Notebook](#) ...

🔍 Search notebooks

⌵ Filters

All Your Work Shared With You Bookmarks

Most Votes ▾



Some Best Practices for Analytics Reporting

Notebook copied with edits from JohnM · Updated 2Y ago
22 comments · CDP - Unlocking Climate Solutions +2

▲ 230

🥇 Gold ...



Tips for making the Informative Visualization

Updated 2Y ago
16 comments · CDP - Unlocking Climate Solutions +2

▲ 113

🥇 Gold ...



Untying Climate's Knots - Visualisation

Updated 2Y ago
39 comments · CDP - Unlocking Climate Solutions

▲ 98

🥇 Gold ...



cdp_starter_notebook

Updated 2Y ago
11 comments · CDP - Unlocking Climate Solutions

▲ 90

🥇 Gold ...



★ Started with Dataviz, Next Step is Data Mining

Updated 2Y ago
12 comments · CDP - Unlocking Climate Solutions +3

▲ 69

🥈 Silver ...

<https://www.kaggle.com/competitions/cdp-unlocking-climate-solutions/code?competitionId=22420&sortBy=voteCount>

Some Best Practices for Analytics Reporting

Python · [Chai Time Data Science](#) | [CTDS.Show](#), [CDP - Unlocking Climate Solutions](#), [NFL Big Data Bowl 2021](#)

Notebook Data Logs Comments (22)



Competition Notebook

[CDP - Unlocking Climate Solutions](#)

Run

12.7s



Version 10 of 10

Data Visualization

Statistical Analysis

In []:



In []:





Kaggle 데이터 분석 Case Study > Most Voted Code

<https://www.kaggle.com/code/subinium/tips-for-making-the-informative-visualization>

<https://www.kaggle.com/code/anshumoudgil/untying-climate-s-knots-visualisation>

<https://www.kaggle.com/code/callumr22/cdp-starter-notebook>



Kaggle 데이터 분석 Case Study > DS4G - Environmental Insights Explorer

≡ kaggle

+ Create

🏠 Home

🏆 Competitions

📁 Datasets

🔗 Code

💬 Discussions

📖 Courses

▼ More

📅 View Active Events

🔍 Search

Sign In

Register

Analytics Competition

DS4G - Environmental Insights Explorer

Exploring alternatives for emissions factor calculations

\$25,000

Prize Money

2 years ago

Overview Data Code Discussion Rules

New Notebook

🔍 Search notebooks

Filters

All Your Work Shared With You Bookmarks

Most Votes



Understanding the Data

Updated 2Y ago
37 comments · DS4G - Environmental Insights Explorer

153

Gold



How to get started with the Earth Engine data

Updated 2Y ago
38 comments · DS4G - Environmental Insights Explorer

112

Gold



DS4G: Go to the Green Future!

Updated 2Y ago
28 comments · DS4G - Environmental Insights Explorer

70

Gold



DS4G: Spatial Panel Data Modeling

Updated 2Y ago
11 comments · DS4G - Environmental Insights Explorer +8

49

Silver



Green Future: Anomaly Analysis & Time Series

Notebook copied with edits from a private notebook · Updated 2Y ago
13 comments · DS4G - Environmental Insights Explorer +1

46

Silver

<https://www.kaggle.com/competitions/ds4g-environmental-insights-explorer/code?competitionId=17907&sortBy=voteCount>



Kaggle 데이터 분석 Case Study > Most Voted Code

<https://www.kaggle.com/code/parulpandey/understanding-the-data>

<https://www.kaggle.com/code/paultimothymooney/how-to-get-started-with-the-earth-engine-data>

<https://www.kaggle.com/code/caesarlupum/ds4g-go-to-the-green-future>



Kaggle 데이터 분석 Case Study > Acea Smart Water Analytics

≡ kaggle

+ Create

🏠 Home

🏆 Competitions

📁 Datasets

<> Code

💬 Discussions

📖 Courses

⌵ More

📅 View Active Events

🔍 Search

Sign In

Register

Analytics Competition

Acea Smart Water Analytics

Can you help preserve "blue gold" using data to predict water availability?

Acea Group · a year ago

\$25,000

Prize Money

Overview Data Code Discussion Rules

New Notebook

🔍 Search notebooks

⌵ Filters

All Your Work Shared With You Bookmarks

Most Votes ▾



TimeSeries Analysis 📊 A Complete Guide 📖

Updated 1y ago

172 comments · Acea Smart Water Analytics

508

🥇 Gold



Intro to Time Series Forecasting

Updated 3mo ago

63 comments · Acea Smart Water Analytics

337

🥇 Gold



EDA: Quenching the Thirst for Insights

Updated 1y ago

42 comments · Acea Smart Water Analytics

108

🥇 Gold



Acea Smart Water: Full EDA & Prediction

Updated 1y ago

55 comments · Acea Smart Water Analytics

89

🥇 Gold



Quick EDA | Reporting & Data Understanding

Updated 2Y ago

32 comments · Acea Smart Water Analytics

83

🥇 Gold

<https://www.kaggle.com/competitions/acea-water-prediction>



Kaggle 데이터 분석 Case Study > Most Voted Code

<https://www.kaggle.com/code/andreshg/timeseries-analysis-a-complete-guide>

<https://www.kaggle.com/code/iamleonie/intro-to-time-series-forecasting>

<https://www.kaggle.com/code/iamleonie/eda-quenching-the-thirst-for-insights>

<https://www.kaggle.com/code/maksymshkliarevskyi/acea-smart-water-full-eda-prediction>

<https://www.kaggle.com/code/ekrembayar/quick-eda-reporting-data-understanding>

<https://www.kaggle.com/code/michau96/how-virtual-trees-can-save-real-water-in-italy>



Dacon 데이터 분석 Case Study



커뮤니티 대회 교육 랭킹 더보기




로그인

회원가입

Just Submit!

다양한 난이도의 중대한 임무가 있습니다.
다수의 열정적인 데이터 전문가들과 동참해서 배우고 멋지게 임무를 해결해 보세요.



음향 데이터 COVID-19 검출 AI 경진대회

월간데이터콘22 | classification | Audio | 정형 | macro-f1



참가신청중

종료 D-27 · 270명

100만원 + α



탄소중립을 위한 기후기술 정보 시각화 경진대회

녹색기술센터 | 기후기술 | 분석시각화



참가신청중

종료 D-15 · 182명

1,000만원



코드 유사성 판단 AI 경진대회

월간데이터콘21 | AI프렌즈 | 대전 AI | Code NLP



연습

718명

총 600만 원



생육 환경 최적화 경진대회

KIST강릉분원 | Vision | 시계열 | 생육데이터 | NMAE



연습

604명

총 300만원



Computer Vision 이상치 탐지 알고리즘 경진대회

월간데이터콘20 | anomaly detection | vision | macro-f1



연습

1,101명

100만원 + α



제 20대 대선 후보 정책·공약 시각화 경진대회

월간데이터콘19 | 시각화 | 대선 | 정책 · 공약



연습

643명

100만원 + α



Dacon 데이터 분석 Case Study > 2021 JOISS 해양과학 빅데이터 활용 경진대회



커뮤니티 **대회** 교육 랭킹 더보기



로그인

회원가입

2021 JOISS 해양과학 빅데이터 활용 경진대회

분석해커톤 | 해양수산부 | 부경대학교 | 해양과학

₩ 상금 : 총 2,000만원

🕒 2021.09.01 ~ 2021.11.02 23:59 [+ Google Calendar](#)

👤 136명 📅 마감



참여

대회안내

데이터

코드 공유

토크

리더보드

제출

개요

📄 규칙

🕒 일정

₩ 상금

📄 동의사항

1.배경

안녕하세요 여러분! 🐋 JOISS 해양과학 빅데이터 활용 경진대회에 오신 것을 환영합니다.

해양과학자료 분석에 기초한 해양물리, 해양화학, 해양생물, 해양지질, 해양기상, 수산응용 분야에서의 지식발견은 해양 과학 발달에 큰 힘이 될 것입니다.

2.목적

오픈사이언스 기반의 '해양과학데이터 저장소(JOISS)'와 오픈 해양데이터 활용
해양 빅데이터 분야의 연구 및 산업 활성화

3.주최/주관

- 주최: 해양수산부
- 주관: 부경대학교, (사)한국해양학회, (사)대한원격탐사학회, (주)환경과학기술, 데이콘

<https://dacon.io/competitions/official/235793/overview/description>



Dacon 데이터 분석 Case Study > Most Voted Code

<https://dacon.io/competitions/official/235793/codeshare/3359?page=1&dtype=random>

<https://dacon.io/competitions/official/235793/codeshare/3642?page=1&dtype=random>

<https://dacon.io/competitions/official/235793/codeshare/3664?page=1&dtype=random>



Dacon 데이터 분석 Case Study > 교통·문화·통신 빅데이터 플랫폼 융합 분석 경진대회

DAICON

커뮤니티 대회 교육 랭킹 더보기



로그인

회원가입

교통·문화·통신 빅데이터 플랫폼 융합 분석 경진대회

한국철도공사 | 한국문화정보원 | KT | 빅데이터 융합 분석 | 투표 및 심사평가

₩ 상금 : 총 1,500만원

🕒 2021.09.06 ~ 2021.10.08 17:59

+ Google Calendar

👤 595명 📅 마감



참여

대회안내

데이터

코드 공유

토크

리더보드

제출

개요

규칙

일정

상금

동의사항

1. 배경

안녕하세요 여러분! 🙋 교통·문화·통신 빅데이터 플랫폼 융합 분석 경진대회에 오신 것을 환영합니다.

COVID-19가 장기간 지속됨에 따라 시민들의 생활 패턴, 지역 경제에 큰 영향을 미치고 있습니다.

한편 지난해 디지털 뉴딜 사업이 시작된 이후 교통/문화/통신 등 산업 분야별로 데이터 공급이 확대되고 있으며,

이와 관련된 데이터를 분석하여 도출해낸 인사이트는 지역 경제 활성화에 큰 역할을 할 수 있습니다.

본 대회는 과기정통부의 빅데이터 플랫폼 및 네트워크 구축 사업으로써

2019년부터 2021년까지의 도시(강릉, 목포, 전주) 관광 인구, 철도 유동 인구 데이터를 비롯하여 전국의 문화/여가 시설 데이터를 제공합니다.

다양한 데이터의 융합 분석을 통해 과학적 기반 정책과 서비스를 추진/발굴 할 수 있을 것으로 예상합니다.

교통/문화/통신 기반의 지역 경제 활성화를 위해 제시된 빅데이터를 분석해주세요!

2. 목적

- 유동/관광 인구와 문화 시설 데이터를 분석해 코로나 시대 유의미한 인사이트 도출
- 빅데이터 분석을 통해 지역 경제 활성화 아이디어 발굴 및 각 기관에서 향후 활용 가능한 정책 및 서비스 제시

<https://dacon.io/competitions/official/235794/overview/description>



Dacon 데이터 분석 Case Study > Most Voted Code

<https://dacon.io/competitions/official/235767/codeshare/3259?page=1&dtype=random>

<https://dacon.io/competitions/official/235767/codeshare/3299?page=1&dtype=random>

<https://dacon.io/competitions/official/235767/codeshare/3288?page=1&dtype=random>



Dacon 데이터 분석 Case Study > 2021 국토교통 빅데이터 온라인 해커톤 경진대회



커뮤니티 대회 교육 랭킹 더보기



로그인

회원가입

2021 국토교통 빅데이터 온라인 해커톤 경진대회

국토교통부 | 빅데이터 | 시각화 | 투표 및 심사평가

₩ 상금 : 총 1,100만원

🕒 2021.07.19 ~ 2021.08.31 18:00

+ Google Calendar

👤 735명 📅 마감



참여

대회안내 데이터 코드 공유 토크 리더보드 제출

개요

규칙

일정

상금

동의사항

1. 배경

안녕하세요 여러분! 🙋 2021 국토교통 빅데이터 온라인 해커톤 경진대회에 오신 것을 환영합니다.

2017년부터 국토교통 데이터와 민간의 창의적인 아이디어를 결합하여, 정책 문제를 해결하기 위한 국토교통 빅데이터 해커톤을 개최해왔습니다.

코로나 이후, 국토교통 데이터 활용으로 변화하는 미래 사업의 기회를 잡으세요.

[참고-작년 경진대회] [2020 국토교통 빅데이터 온라인 해커톤 바로가기](#)

2. 목적

국토교통 공공데이터 이용에 대한 대국민 인식 제고 및 이를 이용, 활성화를 통한 국토·교통 분야 정책 및 창업 아이디어·서비스 발굴

3. 주최 / 주관 / 운영

- 주최 : 국토교통부
- 주관 : 국토연구원, 한국공항공사, 한국도로공사, 한국교통안전공단
- 운영 : 데이콘

<https://dacon.io/competitions/official/235758/overview/description>



Dacon 데이터 분석 Case Study > Most Voted Code

<https://dacon.io/competitions/official/235758/codeshare/3185?page=1&dtype=random>


<https://dacon.io/competitions/official/235758/codeshare/3183?page=1&dtype=random>

<https://dacon.io/competitions/official/235758/codeshare/3152?page=1&dtype=random>

Q&A and Break Time

질의응답 및 휴식시간 (10분)





2부: 회귀분석

- 1) 단순회귀모형 – 가설 & 회귀계수
- 2) 다중회귀모형 – 회귀계수 & 더미변수
- 3) 회귀모형 분석 지표
- 4) 모형 타당성 지표





회귀 분석

1 단순회귀모형 - 가설 & 회귀계수



회귀 분석

1. 회귀 분석 - 독립 & 종속 변수

회귀분석을 사용하는 이유

- 변수 사이의 인과관계가 명확해지고, 한 변수가 다른 변수에 끼치는 영향을 추정할 수 있다

회귀분석 예시

- A 학생의 학급에서는 매주 쪽지시험이 진행되었는데, A학생은 이 쪽지 시험의 평균과 기말고사 점수 사이에 어떤 인과 관계가 있는지에 관심이 있었다.
- 그래서 같은 반 학생들의 기말고사 결과와 쪽지 시험의 평균점수를 차례로 물어보았다.
- 시험 결과 이외에도 기말고사에 영향을 끼칠 것으로 보이는 전날 수면시간과 통학 방법을 함께 데이터로 수집하였다.

* 과연, 어떤 변수가 기말고사에 영향을 끼치게 될까?

- 복잡한 현상이지만, 사람이 이해할 수 있을 정도의 간단한 구조로도 충분히 설명할 수 있는 좋은 모델을 회귀분석으로 만들어보자!



회귀 분석

1. 단순회귀모형 – 가설 & 회귀계수

.

파이썬 기초 라이브러리 세팅

- Numpy (분포 구현)
- Pandas (데이터프레임 활용)
- Matplotlib의 pyplot (데이터 시각화)
- Scipy의 stats 모듈 (통계 계산)
- statsmodels.formula.api의 smf 모듈 (통계 모형)

```
1 import numpy as np
2 import pandas as pd
3 import matplotlib.pyplot as plt
4 from scipy import stats
5 import statsmodels.formula.api as smf
6
7 %precision 3
8 %matplotlib inline
```





데이터 파일

1. 데이터 파일 - 데이터 & 데이터

데이터 파일을 읽기위한 구글드라이브 활용 방법

1. 구글드라이브에 데이터 파일 업로드
2. 주어진 소스를 실행해서 구글드라이브 마운트 진행
3. Colab화면 좌측 상단의 4번째 '폴더' 이미지를 선택해서
content 폴더 아래에 drive/MyDrive 폴더로 접근해서 파일을 찾는다
4. 아래 그림처럼 파일에서 오른쪽버튼을 활용하여 경로 복사 후
pandas.read_csv로 데이터를 읽는다

```
1 from google.colab import drive
2 drive.mount('/content/drive')
```



```
1 # 주소복사 예시
2 training_rel = pd.read_csv('<복사된주소>')
```



회귀 분석

1. 단순회귀모형 – 가설 & 회귀계수

.

[Python] A 학생이 취득한 데이터 호출 (퀴즈 점수, 기말고사 점수, 전날 수면시간, 통학 방법)

```
1 df = pd.read_csv(  
2 |     '/content/drive/MyDrive/@@2021 Fast Campus 강의/확률및통계/ch12_scores_reg.csv'  
3 | )  
4 n = len(df)  
5 print(n)  
6 df.head()
```

20

	quiz	final_test	sleep_time	school_method
0	4.2	67	7.2	bus
1	7.2	71	7.9	bicycle
2	0.0	19	5.3	bus
3	3.0	35	6.8	walk
4	1.5	35	7.5	walk



회귀 분석

1. 단순회귀모형 – 가설 & 회귀계수

회귀분석

- 인과관계가 의심되는 복수의 변수를 사용하여 어느 변수로부터 다른 변수의 값을 예측하는 기법

회귀분석 관련 용어

- 설명변수 (Explanatory Variable) – 독립변수 (Independent Variable)라 부르기도 함
: 원인이 되는 변수
- 반응변수 (Response Variable) – 종속변수 (Dependent Variable)라 부르기도 함
: 결과가 되는 변수

단순회귀모형 (Simple Regression)

- 설명변수와 반응변수가 각각 1개씩인 가장 단순한 모델



회귀 분석

1. 단순회귀모형 – 가설 & 회귀계수

.

[Python] 단순회귀모형의 예시

- 반응변수를 기말고사 점수, 설명변수를 쪽지 시험의 평균 점수로 하는 단순회귀분석 모형
 - y: 기말고사 점수 (반응변수)
 - x: 쪽지 시험의 평균 점수 (설명변수)
 - p: 설명변수의 수

```
1  x = np.array(df[ 'quiz' ])
2  y = np.array(df[ 'final_test' ])
3  p = 1
```





회귀 분석

1. 단순회귀모형 - 가설 & 회귀계수

[Python] 단순회귀모형의 예시 시각화 (산점도 & 회귀직선)

```
1 poly_fit = np.polyfit(x, y, 1)
2 poly_1d = np.poly1d(poly_fit)
3 xs = np.linspace(x.min(), x.max())
4 ys = poly_1d(xs)
5
6 fig = plt.figure(figsize=(10, 6))
7 ax = fig.add_subplot(111)
8 ax.set_xlabel('quiz')
9 ax.set_ylabel('final test')
10 ax.plot(xs, ys, color='gray',
11         label=f'{poly_fit[1]:.2f}+{poly_fit[0]:.2f}x')
12 ax.scatter(x, y)
13 ax.legend()
14
15 plt.show()
```



회귀분석을 위한 가정

- 설명변수 x 와 반응변수 y 사이에 다음과 같은 관계를 가정한다

$$y = \beta_0 + \beta_1 x$$

* 그러나 산점도와 함께 그려진 회귀직선을 보면 알 수 있듯이, 데이터는 직선과 완전히 일치하지 않는다
즉, 예측할 수 없는 부분이 존재하며 이를 오차항(Error Term)이라 하고 ϵ_i 로 나타낸다


- 실제, 기말고사 결과는 아래 식으로 표현된다

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i \quad (i = 1, 2, \dots, n)$$

- 추가로, 회귀분석에서는 다음 2가지를 가정한다

- 설명변수가 확률변수는 아니다
- ϵ_i 는 서로 독립이고 $N(0, \sigma^2)$ 을 따른다

- 가정에 의해, 확률변수 Y_i 는 서로 독립이고 $N(\beta_0 + \beta_1 x_i, \sigma^2)$ 를 따르게 된다





회귀 분석

1. 회귀 분석 - 회귀 & 회귀 분석

회귀분석을 위한 가정의 예

- 쪽지 시험의 평균 점수가 4점인 학생의 기말고사 점수는

$$N(\beta_0 + 4\beta_1, \sigma^2)$$

를 따르는 확률변수로 간주하게 된다

회귀분석 관련 개념

- 회귀분석 : 이러한 가정을 기초로 표본인 $(x_1, Y_1), (x_2, Y_2), \dots, (x_n, Y_n)$ 으로부터 모수 β_0 과 β_1 을 추정하는 것
- 회귀직선 : 모수 β_0 과 β_1 의 추정값인 $\widehat{\beta}_0$ 과 $\widehat{\beta}_1$ 에 의해 생성되는 직선 $y = \widehat{\beta}_0 + \widehat{\beta}_1 x$ 이다
- 회귀계수 : 추정값인 $\widehat{\beta}_0$ 과 $\widehat{\beta}_1$



□□ □□

1. □□□□□□ - □□ & □□□□

.

statsmodels에 의한 회귀분석

- Statsmodels에서 smf.ols 라는 함수에 설명변수 및 반응변수의 관계를 나타내는 문자열 ‘<반응 변수> ~ <설명변수>’ 과 DataFrame을 전달하여 정의 후 fit이라는 함수를 통해서 호출하여 실행할 수 있다.

* smf.ols에서 OLS(Ordinary Least Squares)는 최소제곱법을 뜻한다.

예시) 쪽지시험을 설명변수, 기말고사를 반응변수로서 회귀분석을 수행하고자 한다면,
‘final_test ~ quiz’와 같이 실제 데이터 컬럼명과 매칭되도록 문자열을 입력한다.

- 분석 결과는 summary 메서드(함수)를 통해서 모두 표로 얻을 수 있다.



□□ □□

1. □□□□□□ - □□ & □□□□

.

[Python] statsmodels에 의한 회귀분석

- 쪽지시험을 설명변수, 그리고 기말고사를 반응변수로서 회귀분석 수행시 결과

```
1 formula = 'final_test ~ quiz'
2 result = smf.ols(formula, df).fit()
3 print(result.summary())
```

```

=====
                        OLS Regression Results
=====
Dep. Variable:          final_test      R-squared:                0.676
Model:                  OLS            Adj. R-squared:           0.658
Method:                 Least Squares   F-statistic:               37.61
Date:                  Sun, 17 Oct 2021  Prob (F-statistic):       8.59e-06
Time:                  10:30:25         Log-Likelihood:            -76.325
No. Observations:      20              AIC:                     156.7
Df Residuals:          18              BIC:                     158.6
Df Model:               1
Covariance Type:       nonrobust
=====

```

	coef	std err	t	P> t	[0.025	0.975]
Intercept	23.6995	4.714	5.028	0.000	13.796	33.603
quiz	6.5537	1.069	6.133	0.000	4.309	8.799

```

=====
Omnibus:                 2.139      Durbin-Watson:           1.478
Prob(Omnibus):            0.343      Jarque-Bera (JB):         1.773
Skew:                    0.670      Prob(JB):                 0.412
Kurtosis:                 2.422      Cond. No.                 8.32
=====

```

- Statsmodels의 ols의 summary를 출력시 충분히 많은 양의 분석결과를 확인 가능하다
- 이제부터, 각 표현들이 무엇을 뜻하는지에 대해 하나씩 살펴보도록 하자
 - 1) 모형의 개요 및 데이터에 대한 모형의 적합도
 - 2) 회귀계수의 추정 결과
 - 3) 모형으로부터 얻은 오차항이 정규분포를 따르고 있는지에 대한 가정의 타당성 확인
- 계산 결과 확인은 Numpy, Scipy를 통해서 진행한다



회귀 분석

1. 회귀 분석 - 회귀 & 회귀

회귀계수

- 실제 인과관계로부터 나타나는 모수 β_0 과 β_1 의 추정값인 계수인 $\hat{\beta}_0$ 과 $\hat{\beta}_1$ 이다
- 앞선 출력결과에서는 점추정 뿐만 아니라 구간추정, 그리고 가설검정의 결과도 확인이 가능하다

	coef	std err	t	P> t	[0.025	0.975]
Intercept	23.6995	4.714	5.028	0.000	13.796	33.603
quiz	6.5537	1.069	6.133	0.000	4.309	8.799



회귀 분석

1. 회귀 분석 - 회귀 & 회귀

회귀계수

	coef	std err	t	P> t	[0.025	0.975]
Intercept	23.6995	4.714	5.028	0.000	13.796	33.603
quiz	6.5537	1.069	6.133	0.000	4.309	8.799

- 행 데이터인 Intercept는 절편 β_0 를 뜻하고, Quiz는 기울기 β_1 를 뜻한다
- 열 데이터는 아래와 같이 표현된다
 - coef : 회귀계수의 추정값 $\hat{\beta}_0, \hat{\beta}_1$
 - std err: 추정값의 표준오차
 - t : 회귀계수에 관한 t 검정통계량
 - P>|t| : t의 검정통계량의 p값
 - [0.025와 0.975] : 회귀계수의 95% 신뢰구간



회귀 분석

1. 회귀계수 - 절편 & 기울기

점추정

	coef	std err	t	P> t	[0.025	0.975]
Intercept	23.6995	4.714	5.028	0.000	13.796	33.603
quiz	6.5537	1.069	6.133	0.000	4.309	8.799

1. coef에 출력된 회귀계수의 추정량 $\hat{\beta}_0$, $\hat{\beta}_1$ 의 추정치를 실제로 구한다
2. 구해진 추정치로 생성한 직선 $y = \hat{\beta}_0 + \hat{\beta}_1 x = 23.6995 + 6.5537x$ 은 데이터 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ 에 가장 잘 들어맞는 직선이다




회귀 분석

1. 회귀 분석 - 회귀 & 회귀

데이터와 가장 잘 들어맞는 직선이란?

x_i 로부터 예측된 모형의 예측값 $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ 와 실제의 데이터 y_i 의 차이가 가장 작은 직선

* 엄밀성을 따지자면 $y_i - \hat{y}_i$ 를 잔차(Residual) $\hat{\epsilon}_i$ 로 정의하고, 그 제곱합($\sum_i^n \hat{\epsilon}_i^2$)인 잔차제곱합 (RSS: Residual Sum of Squares)이 가장 작은 직선으로서 정의된다





□□ □□

1. □□□□□□ - □□ & □□□□

.

최소제곱법 (Ordinary Least Squares)

잔차제곱합을 최소화하는 $\hat{\beta}_0$ 와 $\hat{\beta}_1$ 을 구하는 방법

- 최소제곱법으로 구한 $\hat{\beta}_0$ 와 $\hat{\beta}_1$ 는 β_0 와 β_1 의 불편일치추정량이 된다

[Python] 최소제곱법으로 $\hat{\beta}_0$ 와 $\hat{\beta}_1$ 를 구하는 방법

상세한 이론은 선형대수학이나 편미분에 대한 지식이 필요하지만, Numpy로 쉽게 구현해보기



□□ □□

1. □□□□□□ - □□ & □□□□

.

[Python] 최소제곱법으로 $\hat{\beta}_0$ 와 $\hat{\beta}_1$ 를 구하는 방법

상세한 이론은 선형대수학이나 편미분에 대한 지식이 필요하지만, Numpy로 쉽게 구현해보기

1. 첫 번째 열은 $\hat{\beta}_0$ 계산을 위해 전부 1, 두번째 열은 $\hat{\beta}_1$ 계산을 위해 X인 행렬을 생성한다

```
1 X = np.array([np.ones_like(x), x]).T
2 X

array([[1. , 4.2],
       [1. , 7.2],
       [1. , 0. ],
       [1. , 3. ],
       [1. , 1.5],
       [1. , 0.9],
       [1. , 1.9],
       [1. , 3.5],
       [1. , 4. ],
       [1. , 5.4],
       [1. , 4.2],
       [1. , 6.9],
       [1. , 2. ],
       [1. , 8.8],
       [1. , 0.3],
       [1. , 6.7],
       [1. , 4.2],
       [1. , 5.6],
       [1. , 1.4],
       [1. , 2. ]])
```



1

2. Numpy의 linalg.lstsq로 최소제곱법을 실행한다 (첫 번째 인수는 X, 두 번째 인수는 반응변수인

3. $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ 와 잔차 $\hat{\epsilon}_i = y_i - \hat{y}_i$ 를 계산한다

```
1 y_hat = beta0_hat + beta1_hat * x
2 eps_hat = y - y_hat
```



회귀 분석

1. 회귀 분석 - 회귀 & 회귀 분석

[Python] 최소제곱법으로 $\hat{\beta}_0$ 와 $\hat{\beta}_1$ 를 구하는 방법

상세한 이론은 선형대수학이나 편미분에 대한 지식이 필요하지만, Numpy로 쉽게 구현해보기

4. 잔차 $\hat{\epsilon}_i$ 는 오차항 ϵ_i 에 대응하고 있기 때문에, 잔차의 분산으로부터 모분산 σ^2 을 추정할 수 있다
(잔차의 자유도는 회귀계수의 수 $p + 1$ 만큼 감소해서 $n - p - 1$ 이 되므로, 모분산의 불편추정량 $\hat{\sigma}^2$ 은 $n - p - 1$ 로 나누어서 계산되는 값이 된다)

* 설명변수의 수 = p

=> 회귀계수의 수 = $p + 1$

* 예시에서는 회귀계수가 2개였으므로, 자유도는 $n - 2$ 이다

```
1 s_var = np.var(eps_hat, ddof=p+1)
2 s_var
134.290
```



□□ □□

1. □□□□□□ - □□ & □□□□

.

구간추정 (표준오차 및 신뢰구간 계산)

	coef	std err	t	P> t	[0.025	0.975]
Intercept	23.6995	4.714	5.028	0.000	13.796	33.603
quiz	6.5537	1.069	6.133	0.000	4.309	8.799

- β_0 와 β_1 의 구간추정을 진행하기 위해서는 $\widehat{\beta}_0$ 와 $\widehat{\beta}_1$ 의 표준오차가 필요하다
 - $\widehat{\beta}_0$ 와 $\widehat{\beta}_1$ 의 표준오차 구하는 방법
 - $(XX^T)^{-1}$ 의 대각성분의 첫 번째가 C_0 , 두 번째가 C_1 이 되며,
 C_0 와 C_1 은 Numpy에서 구할 수 있다
 - $\widehat{\beta}_0$ 와 $\widehat{\beta}_1$ 의 표준오차는 각각 $\sqrt{C_0\hat{\sigma}^2}$, $\sqrt{C_1\hat{\sigma}^2}$ 이 된다 (앞서 계산한 $\hat{\sigma}^2$ 를 활용해서 계산해보자)

```
1  np.sqrt(s_var * C0), np.sqrt(s_var * C1)

(4.714, 1.069)
```



회귀 분석

1. 회귀계수 - 추정 & 신뢰구간

구간추정 (표준오차 및 신뢰구간 계산)

	coef	std err	t	P> t	[0.025	0.975]
Intercept	23.6995	4.714	5.028	0.000	13.796	33.603
quiz	6.5537	1.069	6.133	0.000	4.309	8.799

2. 회귀계수의 신뢰구간 ($\hat{\sigma}^2$ 의 자유도는 $n-2$)

회귀계수 β_0 와 β_1 의 신뢰수준 $100(1-\alpha)\%$ 의 신뢰구간은 아래와 같이 추정된다

$$\left[\hat{\beta}_i - t_{\alpha/2}(n-2)\sqrt{\hat{\sigma}^2 C_i}, \hat{\beta}_i + t_{1-\alpha/2}(n-2)\sqrt{\hat{\sigma}^2 C_i} \right] \quad (i = 0, 1)$$

```
1 rv = stats.t(n-2)
2
3 lcl = beta0_hat - rv.isf(0.025) * np.sqrt(s_var * C0)
4 hcl = beta0_hat + rv.isf(0.975) * np.sqrt(s_var * C0)
5 lcl, hcl

(13.796, 33.603)
```

```
1 rv = stats.t(n-2)
2
3 lcl = beta1_hat - rv.isf(0.025) * np.sqrt(s_var * C1)
4 hcl = beta1_hat + rv.isf(0.975) * np.sqrt(s_var * C1)
5 lcl, hcl

(4.309, 8.799)
```



회귀 분석

1. 회귀분석 - 회귀 & 회귀분석

t 검정 (회귀계수 β_1)

- $y = \beta_0 + \beta_1 x$ 라는 회귀분석 관계식에서 회귀계수 β_1 에 대한 가설검정
 - 귀무가설 : $\beta_1 = 0$
 - 대립가설 : $\beta_1 \neq 0$
- $\beta_1 = 0$ 에 대한 가설검정에는 $\beta_0 = 0$ 에 대한 동일한 가설검정에 비해 중요한 의미가 하나 더 존재
 - $\beta_1 = 0$ 이 성립한다는 것은 $Y_i = \beta_0 + 0 \times x_i + \epsilon_i = \beta_0 + \epsilon_i$ 와 같이 귀무가설이 채택된다는 것이며, 이는 수식으로 보았을 때 설명변수가 반응변수에 영향을 끼치지 않는다는 것을 의미하기 때문이다
- 위 가설의 검정통계량은 $t = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\hat{\sigma}^2 c_1}}$ 로 정의되며, 잔차의 제약으로부터 자유도가 $n-2$ 인 t분포를 따름
- 최종적으로, 귀무가설 $\beta_1 = 0$ 에 의해 $t = \frac{\hat{\beta}_1}{\sqrt{\hat{\sigma}^2 c_1}}$ 를 계산



회귀 분석

1. 회귀분석 - 회귀 & 회귀분석

[Python] t 검정 (회귀계수 β_1)

- $y = \beta_0 + \beta_1 x$ 라는 회귀분석 관계식에서 회귀계수 β_1 에 대한 가설검정

- 귀무가설 : $\beta_0 = 0$

- 대립가설 : $\beta_0 \neq 0$

	coef	std err	t	P> t	[0.025	0.975]
Intercept	23.6995	4.714	5.028	0.000	13.796	33.603
quiz	6.5537	1.069	6.133	0.000	4.309	8.799

- n-2인 t분포에서 $t = \frac{\hat{\beta}_1}{\sqrt{\hat{\sigma}^2 C_1}}$ 계산 및 p값 계산

- 즉, 귀무가설은 기각이 되어,
꼭지 시험 평균 점수와 기말고사 점수 사이에는
인과관계가 있다고 말할 수 있다

```
1 t = betal_hat / np.sqrt(s_var * C1)
2 t

6.133

1 (1 - rv.cdf(t)) * 2

0.000
```



회귀 분석

1. 회귀분석 - 회귀 & 회귀

[Python] t 검정 (회귀계수 β_0)

- β_1 회귀계수

$y = \beta_0 + \beta_1 x$ 라는 회귀분석 관계식에서 회귀계수 β_0 에 대한 가설검정

- 귀무가설 : $\beta_0 = 0$

- 대립가설 : $\beta_0 \neq 0$

- n-2인 t분포에서 $t = \frac{\hat{\beta}_0}{\sqrt{\hat{\sigma}^2 C_0}}$ 계산 및 p값 계산

- 즉, 귀무가설은 기각이 되어,
 β_0 값 또한 statsmodels의 분석 결과와
동일한 결과가 나옴을 확인할 수 있다

	coef	std err	t	P> t	[0.025	0.975]
Intercept	23.6995	4.714	5.028	0.000	13.796	33.603
quiz	6.5537	1.069	6.133	0.000	4.309	8.799

```
1 t = beta0_hat / np.sqrt(s_var * C0)
2 t

5.028

1 (1 - rv.cdf(t)) * 2

0.000
```



회귀 분석

2 다중회귀모형 – 회귀계수 & 더미변수



다중회귀모형 (Multiple Regression Model)

- 설명변수가 2개 이상인 회귀분석 모형
- p 개의 설명변수 $x_1, x_2, \dots, x_p$ 와 반응변수 y 사이에 아래 관계를 가정한 모형이다

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

다중회귀모형의 예시

- $p=2$ 로서 설명변수로 쪽지 시험 평균 점수 및 시험 전날의 수면 시간을 통해 기말고사 시험 점수를 예측하는 모형을 만들고자 할 때 아래와 같이 표현된다

$$y = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \epsilon_i$$



회귀 분석

2. 다중회귀모형 - 회귀계수 & 더미변수

[Python] statsmodels로 다중회귀모형 회귀분석 수행하기

- 설명변수: 쪽지 시험 평균 점수 및 시험 전날의 수면
반응변수: 기말고사 점수
- statsmodels의 smf.ols함수에 설명변수 문자열 2개를
+로 연결하여 전달한다

```
1 formula = 'final_test ~ quiz + sleep_time'
2 result = smf.ols(formula, df).fit()
3 print(result.summary())
```

```
=====
                        OLS Regression Results
=====
Dep. Variable:          final_test      R-squared:                0.756
Model:                  OLS             Adj. R-squared:          0.727
Method:                 Least Squares    F-statistic:              26.35
Date:                   Mon, 18 Oct 2021  Prob (F-statistic):      6.19e-06
Time:                   03:32:29         Log-Likelihood:          -73.497
No. Observations:       20              AIC:                    153.0
Df Residuals:           17              BIC:                    156.0
Df Model:                2
Covariance Type:        nonrobust
=====
```

	coef	std err	t	P> t	[0.025	0.975]
Intercept	-1.8709	11.635	-0.161	0.874	-26.420	22.678
quiz	6.4289	0.956	6.725	0.000	4.412	8.446
sleep_time	4.1917	1.778	2.357	0.031	0.440	7.943

```
=====
Omnibus:                 2.073      Durbin-Watson:           1.508
Prob(Omnibus):            0.355      Jarque-Bera (JB):         1.716
Skew:                     0.660      Prob(JB):                 0.424
Kurtosis:                 2.437      Cond. No.                 38.0
=====
```



[Python] Numpy로 다중회귀모형의 회귀계수 구하기

- 설명변수 2개($p=2$)를 각각 x_1, x_2 로 표현하고, 반응변수를 y 라고 표현

```
1 x1 = df['quiz']
2 x2 = df['sleep_time']
3 y = df['final_test']
4 p = 2
```

- 단순회귀모형의 경우와 마찬가지로 첫 번째 열은 전부 1, 두 번째 열은 x_1 , 세 번째 열은 x_2 가 되는 행렬 X 를 생성하고, `np.linalg.lstsq` 함수에 의해 최소제곱법을 실행하여 $\beta_0, \beta_1, \beta_2$ 의 추정값인 $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2$ 를 계산한다

```
1 X = np.array([np.ones_like(x1), x1, x2]).T
2 beta0_hat, beta1_hat, beta2_hat = np.linalg.lstsq(X, y)[0]
3 beta0_hat, beta1_hat, beta2_hat
(-1.871, 6.429, 4.192)
```



회귀 분석

2. 다중회귀분석 - 회귀식 & 잔차

[Python] Numpy로 다중회귀모형의 잔차 및 표준오차 구하기

- $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2$ 를 이용하여 $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2}$ 를 계산
 $\hat{\epsilon}_i = y_i - \hat{y}_i$ 를 계산

```
1 y_hat = beta0_hat + betal_hat * x1 + beta2_hat * x2
2 eps_hat = y - y_hat
```

- 표준오차도 단순회귀모형의 방법과 동일하게 계산

```
1 s_var = np.sum(eps_hat ** 2) / (n - p - 1)
2 C0, C1, C2 = np.diag(np.linalg.pinv(np.dot(X.T, X)))
```



[Python] Numpy로 다중회귀모형의 β_2 의 95% 신뢰구간 구하기

- sleep_time 변수의 신뢰구간은 단순회귀모형의 방법과 동일하게 계산

```
1 rv = stats.t(n-p-1)
2
3 lcl = beta2_hat - rv.isf(0.025) * np.sqrt(s_var * C2)
4 hcl = beta2_hat + rv.isf(0.975) * np.sqrt(s_var * C2)
5 lcl, hcl

(0.440, 7.943)
```

- Statsmodels의 95% 신뢰구간 결과와 값이 동일하게 나옴을 확인할 수 있다

```
=====
              coef      std err          t      P>|t|      [0.025      0.975]
-----
Intercept    -1.8709      11.635     -0.161      0.874     -26.420      22.678
quiz          6.4289       0.956      6.725      0.000       4.412       8.446
sleep_time    4.1917       1.778      2.357      0.031       0.440       7.943
=====
```




질적변수를 회귀분석에 활용하고 싶다면?

- 쪽지 시험 평균 점수 및 수면 시간과 같은 양적 변수 데이터 뿐만 아니라, 통학 방법과 같은 질적 변수 데이터로도 회귀분석을 수행해보고 싶을 수 있다
- 하지만, '버스/자전거/도보' 와 같은 문자는 그대로 수식에 넣는 것이 불가능하므로 질적변수를 양적변수로 변환하는 기법이 필요하다
- 이를 대표하는 기법 중 하나가 가변수(Dummy Variable)이다



가변수 (Dummy Variable)

- 가변수는 0과 1을 취하는 2진 변수로서, 변환하고 싶은 질적변수의 카테고리 수에서 하나를 줄인 수만큼 변환된 새로운 변수의 개수가 만들어진다
- 통학 방법 데이터의 카테고리는 '버스/자전거/도보' 총 3개의 카테고리가 있다고 하자
그러면, 가변수는 총 2개가 필요하다 (예시: $x_{\text{도보}}$, $x_{\text{자전거}}$)
* 즉, 버스는 ($x_{\text{버스}} = 1, x_{\text{도보}} = 0$), 자전거는 ($x_{\text{버스}} = 0, x_{\text{도보}} = 1$), 도보는 ($x_{\text{버스}} = 0, x_{\text{도보}} = 0$)로 나타낼 수 있다
- 질적변수를 가변수로 손수 변환하는 것은 번거로운 작업이지만,
statsmodels에서는 이러한 작업을 편하게 진행할 수 있다

$$y = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i\text{버스}} + \beta_4 x_{i\text{도보}} + \epsilon_i$$



회귀 분석

2. 다중회귀분석 - 변수 & 모형

[Python] 가변수 활용하여 다중회귀모형 구하기

$$y = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i\text{도보}} + \beta_4 x_{i\text{자전거}} + \epsilon_i$$

- 손쉽게 smf.ols formula에
school_method라는 변수명을 추가해주면
알아서 새로 생성된 가변수를 기반으로
회귀분석이 진행된다
- 앞서 얘기한 것처럼 버스와 도보를 나타내는
새로운 변수가 추가되었다

```
1 formula = 'final_test ~ quiz + sleep_time + school_method'
2 result = smf.ols(formula, df).fit()
3 print(result.summary())
```

```

OLS Regression Results
=====
Dep. Variable:    final_test    R-squared:            0.782
Model:            OLS          Adj. R-squared:        0.724
Method:            Least Squares    F-statistic:         13.46
Date:            Mon, 18 Oct 2021    Prob (F-statistic):   7.47e-05
Time:            10:55:19          Log-Likelihood:       -72.368
No. Observations: 20             AIC:                 154.7
Df Residuals:     15             BIC:                 159.7
Df Model:         4
Covariance Type:  nonrobust
=====
                    coef    std err          t      P>|t|      [0.025      0.975]
-----
Intercept          1.3330     12.434      0.107     0.916     -25.169     27.835
school_method[T.bus] -1.8118      6.324     -0.286     0.778     -15.292     11.668
school_method[T.walk] -7.6555      6.420     -1.192     0.252     -21.339      6.028
quiz                6.0029      1.033      5.809     0.000      3.800      8.206
sleep_time          4.5238      1.809      2.501     0.024      0.668      8.380
=====
Omnibus:            1.764    Durbin-Watson:       1.418
Prob(Omnibus):      0.414    Jarque-Bera (JB):     0.989
Skew:               0.545    Prob(JB):             0.610
Kurtosis:           2.985    Cond. No.             41.8
=====
```



회귀 분석

3 회귀모형 분석 지표



□□ □□

3. □□□□ □□□□

.

좋은 모델을 구분하는 기준

1. 적합성이 높은 것

- 모델이 주변 데이터에 유의미하게 들어맞는다
즉, 회귀직선이 데이터에 완전하게 잘 들어맞는 편이며 잔차가 작을 때를 의미한다

2. 예측력이 높은 것

- 주변 데이터로 만든 모델이 미지의 데이터를 어느 정도 예측할 수 있다
즉, 모르는 데이터의 설명변수임에도 모델이 반응변수를 정확하게 예측할 수 있는 편일 때를 의미한다



좋은 모형을 생성 및 고르는 방법

1. 적합성 높이기

- 설명변수의 수를 지속적으로 증가시키면, 적합성이 높아진다
- 문제점

너무 많은 수의 설명변수가 사용되면 오히려 과적합 현상(Overfitting)이 발생하게 되면서 예측 정확도가 떨어지게 된다

2. 예측력 중심으로 높은 모형을 것의 중요성

- 매우 복잡한 모형은 표현력이 너무 높아서 나머지 주변 데이터에 지나치게 적합되어 일반적인 예측성을 잃어버린다
- 따라서, 모형을 고를 때는 적합도보다 예측 정확도가 좋은 것을 골라야 한다



□□ □□

3. □□□□ □□□□

[Python] statsmodels를 통해 모형의 좋고 나쁨을 측정하는 지표 살펴보기

- 쪽지 시험 평균 점수로
기말고사 점수 예측하는 회귀분석 진행
- 빨간 네모 안의 지표들에 대해 알아보자!

```
1 x = np.array(df['quiz'])
2 y = np.array(df['final_test'])
3 p = 1
4
5 formula = 'final_test ~ quiz'
6 result = smf.ols(formula, df).fit()
7 print(result.summary())
```

OLS Regression Results

Dep. Variable:	final_test	R-squared:	0.676
Model:	OLS	Adj. R-squared:	0.658
Method:	Least Squares	F-statistic:	37.61
Date:	Mon, 18 Oct 2021	Prob (F-statistic):	8.59e-06
Time:	11:03:03	Log-Likelihood:	-76.325
No. Observations:	20	AIC:	156.7
Df Residuals:	18	BIC:	158.6
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
Intercept	23.6995	4.714	5.028	0.000	13.796	33.603
quiz	6.5537	1.069	6.133	0.000	4.309	8.799

Omnibus:	2.139	Durbin-Watson:	1.478
Prob(Omnibus):	0.343	Jarque-Bera (JB):	1.773
Skew:	0.670	Prob(JB):	0.412
Kurtosis:	2.422	Cond. No.	8.32



회귀 분석

3. 회귀 분석 결과 해석

좋은 모형을 고르는 지표 1) 잔차제곱합

회귀직선을 구하기 위해 사용되는 잔차제곱합 확인하기

1. 먼저 $\hat{y}_i$ 와 $\hat{\epsilon}_i = y_i - \hat{y}_i$ 준비하기
 - $\hat{y}_i$ 은 result의 fittedvalues라는 인스턴스 변수에서 가져오기
 - $\hat{\epsilon}_i$ 는 result의 resid라는 인스턴스 변수에서 가져오기
(Series이므로 array로 변경)
2. 잔차제곱합 $\sum_{i=1}^n \hat{\epsilon}_i^2$ 계산하기

잔차제곱합의 경우는

동일한 구조의 모형 중에서 상대적으로 비교하는데 사용되며

다른 구조의 모형끼리의 적합도 비교를 위해서는 사용이 어렵다

```

1  y_hat = np.array(result.fittedvalues)
2  y_hat

array([51.225, 70.886, 23.699, 43.361, 33.53 , 29.598, 36.152, 46.638,
       49.914, 59.09 , 51.225, 68.92 , 36.807, 81.372, 25.666, 67.61 ,
       51.225, 60.4  , 32.875, 36.807])

1  eps_hat = np.array(result.resid)
2  eps_hat

array([ 15.775,   0.114,  -4.699,  -8.361,   1.47 ,  10.402, -13.152,
        -9.638, -10.914,  -4.09 , -11.225,   1.08 ,  -7.807,   6.628,
        21.334,   9.39 ,   0.775,  -5.4  , -14.875,  23.193])

1  np.sum(eps_hat ** 2)

2417.228

```




□□ □□

3. □□□□ □□□□

좋은 모형을 고르는 지표 2) 결정계수

결정계수 (R^2 : R-squared)

- 모형의 데이터에 대한 적합도를 나타내는 기본적인 지표
- Statsmodels의 결과로는 R-squared로 출력되어있음
- 결정계수는 0과 1사이의 값을 취한다
=> 1에 가까울수록 모델은 데이터에 잘 들어맞는다

```
R-squared:      0.676
Adj. R-squared:  0.658
F-statistic:     37.61
Prob (F-statistic): 8.59e-06
Log-Likelihood: -76.325
AIC:            156.7
BIC:            158.6
```



회귀 분석

3. 결정계수

좋은 모형을 고르는 지표 2) 결정계수

결정계수 산식

$$R^2 = \frac{\text{회귀변동}}{\text{총변동}} = 1 - \frac{\text{잔차변동}}{\text{총변동}} \quad (\text{총변동} = \text{회귀변동} + \text{잔차변동})$$

- 총변동 : 관측값 y_i 의 $\bar{y}$ (y_i 의 평균값)에 대한 분산도를 나타내는 지표
- 회귀변동 : 예측값 $\hat{y}_i$ 의 $\bar{y}$ (y_i 의 평균값)에 대한 분산도를 나타내는 지표 ($\sum_{i=1}^n (\hat{y}_i - \bar{y})^2$)
- 잔차변동 : 잔차 $\hat{\epsilon}_i$ (관측값 - 예측값 = $y_i - \hat{y}_i$)의 산포도 ($\sum_{i=1}^n \hat{\epsilon}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$)
즉, 예측값이 관측값에 가까울수록

회귀변동은 총변동에 가까운 값이 되어 1에 가까울수록 좋은 모형이 된다

* 단순회귀모형에서는 결정계수가 상관계수의 제곱값과 일치한다

```
R-squared:      0.676
Adj. R-squared:  0.658
F-statistic:     37.61
Prob (F-statistic): 8.59e-06
Log-Likelihood: -76.325
AIC:            156.7
BIC:            158.6
```

```
1 total_var = np.sum((y - np.mean(y))**2)
2 exp_var = np.sum((y_hat - np.mean(y))**2)
3 unexp_var = np.sum(eps_hat ** 2)

1 total_var, exp_var + unexp_var
(7468.550, 7468.550)

1 exp_var / total_var
0.676

1 np.corrcoef(x, y)[0, 1] ** 2
0.676
```



□□ □□

3. □□□□ □□□□

좋은 모형을 고르는 지표 2) 결정계수

결정계수 모형별 비교분석

- 기말고사 ~ 쪽지 시험 : 0.676
- 기말고사 ~ 쪽지 시험 + 수면 시간 : 0.756
- 기말고사 ~ 쪽지 시험 + 수면 시간 + 통학 방법 : 0.782

⇒ 설명변수가 늘어날수록 결정계수가 늘어남을 확인할 수 있다

⇒ 결정계수는 일반적으로 유의미하지 않은 설명변수가 추가되더라도

그 수가 커지면 커질수록 결정계수가 1에 가까워진다고 알려져 있다

⇒ 따라서, 유의미한 설명변수가 추가되어서 좋은 모형이 생성되었는지를 파악하기 위한 새로운 지표 '조정결정계수'를 아는 것이 중요하다

```
R-squared: 0.676
Adj. R-squared: 0.658
F-statistic: 37.61
Prob (F-statistic): 8.59e-06
Log-Likelihood: -76.325
AIC: 156.7
BIC: 158.6
```

```
1 total_var = np.sum((y - np.mean(y))**2)
2 exp_var = np.sum((y_hat - np.mean(y))**2)
3 unexp_var = np.sum(eps_hat ** 2)

1 total_var, exp_var + unexp_var
(7468.550, 7468.550)

1 exp_var / total_var
0.676

1 np.corrcoef(x, y)[0, 1] ** 2
0.676
```



□□ □□

3. □□□□ □□□□

좋은 모형을 고르는 지표 3) 조정결정계수

조정결정계수 ($\bar{R}^2$: Adjusted R-square)

- 설명변수를 추가했을 때 그 설명 변수의 설명력이 기준 이하인 경우 결정계수의 값이 증가되지 않도록 조정하는 결정계수
- Statsmodels의 결과로는 Adj. R-squared로 출력되어있음
- 자유도를 고려한 결정계수로서 ‘자유도조정 결정계수’로도 불리운다

조정결정계수 산식

$$\bar{R}^2 = 1 - \frac{\text{잔차변동}/n-p-1}{\text{총변동}/n-1}$$

```
1  1 - (unexp_var / (n - p - 1)) / (total_var / (n - 1))
0.658
```

⇒ 총변동의 자유도(n-1) = 회귀변동의 자유도(p) + 잔차변동의 자유도 (n-p-1)

⇒ Statsmodels 분석결과 해석시,

```
Df Residuals:    18
Df Model:        1
```

‘Df Model’는 회귀변동의 자유도, ‘Df Residuals’는 잔차변동의 자유도를 의미한다

```
R-squared:        0.676
Adj. R-squared:    0.658
F-statistic:       37.61
Prob (F-statistic): 8.59e-06
Log-Likelihood:    -76.325
AIC:               156.7
BIC:               158.6
```



□□ □□

3. □□□□ □□□□

좋은 모형을 고르는 지표 3) 조정결정계수

조정결정계수 모형별 비교분석

- 기말고사 ~ 쪽지 시험 : 0.658
- 기말고사 ~ 쪽지 시험 + 수면 시간 : 0.727
- 기말고사 ~ 쪽지 시험 + 수면 시간 + 통학 방법 : 0.724

즉, 조정결정계수를 기반으로 **쪽지 시험과 수면 시간**을 설명변수로 생성한 모델의 적합도가 가장 높음을 알 수 있다

R-squared:	0.676
Adj. R-squared:	0.658
F-statistic:	37.61
Prob (F-statistic):	8.59e-06
Log-Likelihood:	-76.325
AIC:	156.7
BIC:	158.6



□□ □□

3. □□□□ □□□□

좋은 모형을 고르는 지표 4) F 검정통계량

F 검정

- 절편 β_0 이외의 회귀계수에 대해 유의성을 진행하는 가설 검정
 - 귀무가설 : $\beta_1 = \beta_2 = \dots = \beta_p = 0$
 - 대립가설 : 적어도 하나의 β_i 는 0이 아니다
- 모형 전체에 대해서 수행되는 검정이다
- F 검정통계량은 statsmodels 분석 결과의 F-statistic 으로, p값은 Prob(F-statistic)으로 출력된다

```

R-squared:          0.676
Adj. R-squared:     0.658
F-statistic:         37.61
Prob (F-statistic):  8.59e-06
Log-Likelihood:     -76.325
AIC:                 156.7
BIC:                 158.6

```

F 검정통계량 산식

- 상단의 단측 검정을 수행하는 자유도가 (p, n-p-1)인 F 검정을 따른다
- $$F = \frac{\text{회귀변동}/p}{\text{잔차변동}/n-p-1}$$
- 모형의 적합도가 높을수록 잔차변동보다 회귀변동이 커지는 것을 이용한

```

1  f = (exp_var / p) / (unexp_var / (n - p - 1))
2  f

37.615

1  rv = stats.f(p, n-p-1)
2  1 - rv.cdf(f)

0.000

```



□□ □□

3. □□□□ □□□□

좋은 모형을 고르는 지표 5) 최대로그우도 / AIC / BIC

우도 (Likelihood)

- 어떤 관측값을 얻을 확률
 - 예시 : 앞면(1)이 나올 확률이 0.3, 뒷면(0)이 나올 확률이 0.7인 뒤틀린 동전을 5회 던졌을 때,
[1,0,1,0,0]이 결과로 나올 확률은 $0.7 \times 0.3 \times 0.7 \times 0.3 \times 0.3 \cong 0.031$ 이다
- 우도의 일반화

동전의 확률함수를 $f(x) = \begin{cases} p & x = \text{앞면} \\ 1-p & x = \text{뒷면} \end{cases}$ 로 가정하고, 얻은 관측값을 x_1, x_2, x_3, x_4, x_5 라 하자

우도 L은 아래와 같다

$$L = \prod_{i=1}^n f(x_i) = p^2(1-p)^3$$

```
R-squared: 0.676
Adj. R-squared: 0.658
F-statistic: 37.61
Prob (F-statistic): 8.59e-06
Log-Likelihood: -76.325
AIC: 156.7
BIC: 158.6
```

```
1 prob = 0.3
2 coin_result = [0, 1, 0, 0, 1]
3
4 rv = stats.bernoulli(prob)
5 L = np.prod(rv.pmf(coin_result))
6 L
0.031
```



☐☐ ☐☐

3. ☐☐☐☐ ☐☐☐☐

좋은 모형을 고르는 지표 5) 최대로그우도 / AIC / BIC

우도 (Likelihood)

- 우도 L의 확률 p가 변한다면?

$$L(p) = \prod_{i=1}^n f(x_i) = p^2(1-p)^3$$

이를 우도함수(Likelihood Function)라 부른다

- p가 0에서 1로 변화될 때의 우도함수를 그려보면 다음과 같다
p가 약 0.4일 때 우도가 최대가 되는 것을 알 수 있다

최우추정법

- 관측값에서 가장 높은 우도가 나오는 p를 추정하는 방법

```


R-squared:      0.676
Adj. R-squared: 0.658
F-statistic:    37.61
Prob (F-statistic): 8.59e-06
Log-Likelihood: -76.325
AIC:            156.7
BIC:            158.6

```

```

1 ps = np.linspace(0, 1, 100)
2 Ls = [np.prod(stats.bernoulli(prob).pmf(coin_result))
3       for prob in ps]
4
5 fig = plt.figure(figsize=(10, 6))
6 ax = fig.add_subplot(111)
7 ax.plot(ps, Ls, label='likelihood function', color='gray')
8 ax.legend(fontsize=16)
9 plt.show()

```





○○ ○○

3. ○○○○ ○○○○

좋은 모형을 고르는 지표 5) 최대로그우도 / AIC / BIC

로그우도 (Log-Likelihood)

- 우도 $L(p) = \prod_{i=1}^n f(x_i)$ 는 곱하면 곱할수록 0이 되는 성질을 가지므로 값이 너무 작아지면 손으로도, 컴퓨터로도 다루기가 어려워진다
- 이를 해결하기 위해 우도에 로그를 취한 것이 바로 **로그우도**이다

```
R-squared:      0.676
Adj. R-squared:  0.658
F-statistic:     37.61
Prob (F-statistic): 8.59e-06
Log-Likelihood: -76.325
AIC:            156.7
BIC:            158.6
```

로그우도 산식

- $\text{Log}(L(p)) = \sum_{i=1}^n \log(f(x_i))$

최우추정과 최대로그우도

- 로그우도함수가 최대가 될 때의 파라미터
- 그 때의 로그우도 값 => 최대로그우도

```
1 prob = 0.4
2 rv = stats.bernoulli(prob)
3 mll = np.sum(np.log(rv.pmf([0, 1, 0, 0, 1])))
4 mll

-3.365
```



□□ □□

3. □□□□ □□□□

좋은 모형을 고르는 지표 5) 최대로그우도 / AIC / BIC

최대로그우도 (Maximum Log-Likelihood)

- 단순회귀모형에서의 가정인 함수 $Y_i \sim N(\beta_0 + \beta_1 x_1, \sigma^2)$ 가 있다고 하자
- $\beta_0, \beta_1, \sigma^2$ 의 최우추정량은 각각 $\hat{\beta}_0, \hat{\beta}_1, \frac{1}{n} \sum_{i=1}^n \hat{\epsilon}_i^2$ 가 된다고 알려져있으므로,
최우추정량을 대입해서 로그우도 관측값으로서 $N(\hat{\beta}_0 + \hat{\beta}_1 x_1, \frac{1}{n} \sum_{i=1}^n \hat{\epsilon}_i^2)$ 의 밀도함수로 최대로그우도를 구한다

```
R-squared: 0.676
Adj. R-squared: 0.658
F-statistic: 37.61
Prob (F-statistic): 8.59e-06
Log-Likelihood: -76.325
AIC: 156.7
BIC: 158.6
```

최대로그우도 모형별 비교분석

- 기말고사 ~ 쪽지 시험 : -76.325
- 기말고사 ~ 쪽지 시험 + 수면 시간 : -73.497
- 기말고사 ~ 쪽지 시험 + 수면 시간 + 통학 방법 : -72.368

```
1 rv = stats.norm(y_hat, np.sqrt(unexp_var / n))
2 mll = np.sum(np.log(rv.pdf(y)))
3 mll
-76.325
```

최대로그우도 기준으로는 **모든 변수**를 설명변수로 생성한 모델의 적합도가 가장 높음을 알 수 있으며,
최대로그우도 또한 설명변수의 수를 늘리면 그 값이 증가하는 특징이 있는 지표이다



☐☐ ☐☐

3. ☐☐☐☐ ☐☐☐☐

좋은 모형을 고르는 지표 5) 최대로그우도 / AIC / BIC

AIC (Akaike's information Criterion)

- 최대로그우도의 단점을 보완하기 위해, 일반적인 성능을 추가로 반영한 지
- AIC 산식 = $-2 \times \text{최대로그우도} + 2 \times \text{회귀계수의 수}$
- 값이 작을수록 예측 정확도가 좋음

```
R-squared: 0.676
Adj. R-squared: 0.658
F-statistic: 37.61
Prob (F-statistic): 8.59e-06
Log-Likelihood: -76.325
AIC: 156.7
BIC: 158.6
```

```
1 aic = -2 * mll + 2 * (p+1)
2 aic

156.650
```

AIC 모형별 비교분석

- 기말고사 ~ 쪽지 시험 : 156.7
- 기말고사 ~ 쪽지 시험 + 수면 시간 : 153.0
- 기말고사 ~ 쪽지 시험 + 수면 시간 + 통학 방법 : 154.7

AIC 기준으로는 쪽지 시험과 수면 시간을 설명변수로 생성한 모델의 적합도가 가장 높음을 알 수 있다



□□ □□

3. □□□□ □□□□

좋은 모델을 고르는 지표 5) 최대로그우도 / AIC / BIC

BIC (Bayesian information Criterion)

- AIC와 유사한 지표
- BIC 산식 = $-2 \times \text{최대로그우도} + \log n \times \text{회귀계수의 수}$
- 값이 작을수록 예측 정확도가 좋음

```
R-squared: 0.676
Adj. R-squared: 0.658
F-statistic: 37.61
Prob (F-statistic): 8.59e-06
Log-Likelihood: -76.325
AIC: 156.7
BIC: 158.6
```

```
1 bic = -2 * mll + np.log(n) * (p+1)
2 bic

158.642
```

BIC 모형별 비교분석

- 기말고사 ~ 쪽지 시험 : 158.6
- 기말고사 ~ 쪽지 시험 + 수면 시간 : 156.0
- 기말고사 ~ 쪽지 시험 + 수면 시간 + 통학 방법 : 159.7

BIC 기준 또한 쪽지 시험과 수면 시간을 설명변수로 생성한 모델의 적합도가 가장 높음을 알 수 있다



회귀 분석

4 모형 타당성 지표



모형의 타당성

- 회귀분석에서의 가정인
'오차항 ϵ_i 는 서로 독립이고 $N(0, \sigma^2)$ 를 따른다'라는 가정을 만족하고 있는지 여부를 확인하는 것
- Statsmodels의 분석 결과 가장 아래 부분에 모형의 타당성에 대한 정보가 출력되어있다
- 오차항 ϵ_i 에 대한 확인을 위해,
잔차 $\hat{\epsilon}_i$ 를 분석하도록 한다

```
1 eps_hat = np.array(result.resid)
```

```
1 formula = 'final_test ~ quiz + sleep_time'
2 result = smf.ols(formula, df).fit()
3 print(result.summary())
```

OLS Regression Results						
=====						
Dep. Variable:	final_test	R-squared:	0.756			
Model:	OLS	Adj. R-squared:	0.727			
Method:	Least Squares	F-statistic:	26.35			
Date:	Mon, 18 Oct 2021	Prob (F-statistic):	6.19e-06			
Time:	18:22:55	Log-Likelihood:	-73.497			
No. Observations:	20	AIC:	153.0			
Df Residuals:	17	BIC:	156.0			
Df Model:	2					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

Intercept	-1.8709	11.635	-0.161	0.874	-26.420	22.678
quiz	6.4289	0.956	6.725	0.000	4.412	8.446
sleep_time	4.1917	1.778	2.357	0.031	0.440	7.943
=====						
Omnibus:	2.073	Durbin-Watson:	1.508			
Prob(Omnibus):	0.355	Jarque-Bera (JB):	1.716			
Skew:	0.660	Prob(JB):	0.424			
Kurtosis:	2.437	Cond. No.	38.0			
=====						



모형의 타당성 지표 1) 정규성 검정

```
=====
Omnibus:                2.073    Durbin-Watson:           1.508
Prob(Omnibus):           0.355    Jarque-Bera (JB):        1.716
Skew:                    0.660    Prob(JB):                0.424
Kurtosis:                2.437    Cond. No.                38.0
=====
```

- 오차항 ϵ_i 이 $N(0, \sigma^2)$ 를 따른다는 가정을 만족하는지 알아보기위해, 잔차 $\hat{\epsilon}_i$ 가 정규분포를 따르는지 확인해보는 정규성 검정을 수행한다
- statsmodels에서는 정규성 검정으로 Omnibus 검정과 Jarque-Bera 검정이 사용되며, Omnibus, Jarque-Bera (JB)로 출력되어있다
- 정규성 검정의 가설은 아래와 같다
 - 귀무가설 : 잔차항은 정규분포를 따른다
 - 대립가설 : 잔차항은 정규분포를 따르지 않는다
- p값인 Prob(Omnibus)와 Prob(JB)가 유의수준인 0.05보다 크면 문제없이 귀무가설을 채택하게 된다



모형의 타당성 지표 1) 정규성 검정

- 왜도 (Skewness) : 분포의 좌우대칭을 측정하는 지표

- 계산식은 $\sum_{i=1}^n \left(\frac{x - \bar{x}}{s} \right)^3$ 이다

- 좌우대칭인 분포면 0이 되고, 왼쪽으로 치우친 분포이면 0보다 크고, 오른쪽으로 치우친 분포이면 0보다 작다

- stats.skew로 계산 가능하다

- 첨도 (Kurtosis) : 분포의 뾰족한 정도를 측정하는 지표

- 계산식은 $\sum_{i=1}^n \left(\frac{x - \bar{x}}{s} \right)^4$ 이다

- 정규분포이면 3이 되고, 정규분포보다 뾰족한 정점을 가진 분포이면 3보다 크고, 정규분포보다 완만한 정점을 가진 분포라면 3보다 작은 값이 된다

- stats.kurtosis의 인수 fisher를 False로 입력하여 계산 가능하다

```
=====
Omnibus:          2.073      Durbin-Watson:          1.508
Prob(Omnibus):    0.355      Jarque-Bera (JB):      1.716
Skew:             0.660      Prob(JB):              0.424
Kurtosis:         2.437      Cond. No.              38.0
=====
```

```
1 stats.skew(eps_hat)

0.660
```

```
1 stats.kurtosis(eps_hat, fisher=False)

2.437
```




회귀 분석

4. 회귀 분석 결과

모형의 타당성 지표 2) 더빈-왓슨비

- 더빈-왓슨비(Durbin-Watson Ratio)
 - 회귀 분석 결과 회귀 잔차의 자기상관을 측정하는 지표
 - 더빈-왓슨비 = $\frac{\sum_{i=2}^n (\hat{\epsilon}_i - \hat{\epsilon}_{i-1})^2}{\sum_{i=1}^n \hat{\epsilon}_i^2}$ 이다
 - 더빈-왓슨비는 0부터 4의 값을 가지며,
 - 0에 가까우면 양의 상관,
 - 4에 가까우면 음의 상관,
 - 2 근처에 존재하면 무상관이라고 판단한다

```
=====
Omnibus:                2.073    Durbin-Watson:           1.508
Prob(Omnibus):           0.355    Jarque-Bera (JB):        1.716
Skew:                    0.660    Prob(JB):                 0.424
Kurtosis:                2.437    Cond. No.                 38.0
=====
```

```
1 np.sum(np.diff(eps_hat, 1) ** 2) / np.sum(eps_hat ** 2)

1.508
```



모형의 타당성 지표 3) 다중공선성

- 다중공선성(Multi-Collinearity)

- 설명변수들 간에 독립 성립되지 않고, 강한 상관관계가 나타나는지 여부를 파악하는 지표
- statsmodels의 분석결과에서는 조건수(Cond. No.)로 표현이 된다
- 조건수의 값이 크면 설명변수들 간에 강한 상관성이 생겼다는 것을 의미한다

- 다중공선성 예시

- 쪽지 시험의 결과를 정확히 2배로 한 중간고사라는 변수를 추가해보자

쪽지 시험과 중간고사 점수의 상관관계는 1이 되며 조건수는 매우 큰 값을 가지게 된다

```
1 df['mid_test'] = df['quiz'] * 2
2 df.head()
```

	quiz	final_test	sleep_time	school_method	mid_test
0	4.2	67	7.2	bus	8.4
1	7.2	71	7.9	bicycle	14.4
2	0.0	19	5.3	bus	0.0
3	3.0	35	6.8	walk	6.0
4	1.5	35	7.5	walk	3.0

```
1 formula = 'final_test ~ quiz + mid_test'
2 result = smf.ols(formula, df).fit()
3 print(result.summary())
```

	coef	std err	t	P> t	[0.025	0.975]
Intercept	23.6995	4.714	5.028	0.000	13.796	33.603
quiz	1.3107	0.214	6.133	0.000	0.862	1.760
mid_test	2.6215	0.427	6.133	0.000	1.723	3.519
Omnibus:		2.139	Durbin-Watson:		1.478	
Prob(Omnibus):		0.343	Jarque-Bera (JB):		1.773	
Skew:		0.670	Prob(JB):		0.412	
Kurtosis:		2.422	Cond. No.		1.04e+17	

Omnibus:	2.073	Durbin-Watson:	1.508
Prob(Omnibus):	0.355	Jarque-Bera (JB):	1.716
Skew:	0.660	Prob(JB):	0.424
Kurtosis:	2.437	Cond. No.	38.0

Q&A

질의응답 (5분)





다음주는 최종 프로젝트 발표날!

Contents for Next Week

프로젝트 제출물 리스트



프로젝트 보고서 Word
(PDF로 제출)

[도시데이터코딩] 1팀 프로젝트 보고서.pdf



소스코드
(ipynb file & Data File)

[도시데이터코딩] 1팀 프로젝트 소스코드.ipynb

[도시데이터코딩] 1팀 프로젝트 데이터.csv



발표자료 PPT
(PDF로 제출)

[도시데이터코딩] 1팀 프로젝트 발표자료.pdf



끝. 감사합니다.

수업 듣느라 수고하셨습니다.

